

1. 考虑图(a)所示的 3×3 世界。转移模型与 4×3 图 17.1 中的相同：80%的概率，智能体朝所选择的方向移动；其余概率以直角方向移动到预期方向。

对于下面每个 r 值，实现价值迭代(value iteration)。使用折扣因子为 0.99 的折扣奖励。展示每种情况下获得的策略。直观地解释 r 值如何导致每个策略。

a. $r=100$

b. $r=-3$

c. $r=0$

d. $r=+3$

r	-1	+10
-1	-1	-1
-1	-1	-1

(a)

+50	-1	-1	-1	...	-1	-1	-1	-1
Start				...				
-50	+1	+1	+1	...	+1	+1	+1	+1

(b)

图(a) 3×3 世界，适用于题目 1。每个状态的奖励已标出。右上方的方块是终止状态。

图(b) 101×3 世界，适用于题目 2（省略了中间 93 个相同的列）。起始状态的奖励为 0。

2. 考虑图(b)中所示的 101×3 世界。在起始状态下，智能体有两个确定性动作的选择：向上 (Up) 或向下 (Down)，而在其他状态下，智能体只有一个确定性动作：向右 (Right)。假设有一个折扣奖励函数，折扣因子 γ 等于多少时智能体应该旋转选择向上 (Up) 和向下 (Down)？计算每个动作的效用 (utility) 作为 γ 的函数。（注意，这个简单的例子实际上反映了许多现实世界的情况，在这些情况下，人们必须权衡立即行动的价值与潜在的长期后果，例如选择向湖中倾倒污染物。）

1. 已知转移模型，即奖励矩阵 R ，考虑 r 几种不同情况，在折扣因子为 0.99 的情况下，实现价值迭代和策略描述

已知对非终止状态 s : $U_{k+1}(s) = R(s) + 0.99 \max_a \sum_{s'} P(s'|s, a) U_k(s')$

当 $\Delta = \max_s |U_{k+1}(s) - U_k(s)| < \epsilon$ (如 $\epsilon = 10^{-6}$ 时收敛)

本题不要求算出收敛时的状态价值，但建议自行手算 1-2 轮

① $r = 100$ 时

$T \backslash C$	$\leftarrow$	$\cdot$
$\uparrow$	$\leftarrow$	$\downarrow$
$\uparrow$	$\leftarrow$	$\leftarrow$

r 给的奖励远大于终点，故智能体会尽可能在 r 处长期停留

② $r = -3$ 时

	$\rightarrow$	$\rightarrow$	$\cdot$
$\rightarrow$	$\rightarrow$	$\rightarrow$	$\uparrow$
$\rightarrow$	$\rightarrow$	$\rightarrow$	$\uparrow$

此时左上角 -3 是最大的惩罚，也是智能体要尽快避开的区域，此时智能体会用尽可能少的步数到达终点

③ $r=0$ 时

→	→	.
↑	↑	↑
↑	↑	↑

此时左上角的奖励大于其它点，但仍小于终点，故智能体会尽可能少的步数到达终点，且经过左上角的点。

④ $r=-3$ 时

↑	←	.
↑	←	↓
↑	←	←

此时虽然单次奖励在左上角不如终点，但终点的10只能获得一次，若长期在左上角则回报为 $3 + 0.99 \cdot 3 + \dots$ ，比到终点更有价值。

2. 分析可知

若选择 Up: 则先得到很大的奖励, 后续长期小惩罚

若选择 Down: 先得到很大的惩罚, 后续长期小奖励

计算累计奖励 $G = R_0 + rR_1 + r^2R_2 + \dots$

$$U_{\text{up}}(r) = 50 - r - r^2 - r^3 - \dots - r^{100} = 50 - \sum_{k=1}^{100} r^k$$
$$= 50 - \frac{r(1-r^{100})}{1-r}$$

$$U_{\text{down}}(r) = -50 + r + r^2 + \dots + r^{100} = -50 + \sum_{k=1}^{100} r^k$$
$$= -50 + \frac{r(1-r^{100})}{1-r}$$

若二者相等, 则 $\frac{r(1-r^{100})}{1-r} = 50 \Rightarrow r^* \approx 0.9844$

故 $\begin{cases} 0 \leq r < 0.9844, & \text{选择 Up} \\ 0.9844 < r \leq 1, & \text{选择 Down} \end{cases}$